

## Big Data

### Características (3V):

- Volumen
- Variedad (estructurados, no estructurados, semiestructurados)
- Velocidad
- Problema: métodos tradicionales no bastan

### Aplicaciones:

- Data Science: estadística, programación, ML
- Business Intelligence (BI): reportes, dashboards, visualizaciones

## Hadoop

Almacenamiento (HDFS):  
Archivos → bloques → nodos

- Replicación → tolerancia a fallos
- Procesamiento (MapReduce):
- Map: divide tareas
- Reduce: combina resultados
- Gestión de recursos (YARN):
- Resource Manager (coordina recursos)
- Node Manager (administra cada nodo)
- Application Master (gestiona apps)

## Apache Spark

### Cluster:

- Nodo Maestro → reparte tareas
- Nodos Trabajadores → procesan en paralelo

### Procesamiento distribuido:

- Datos repartidos por máquinas
- Soporta Excel, JSON, CSV, Parquet, etc.

### Librerías:

- MLlib: Machine Learning
- GraphX: grafos
- PySpark: usar Spark con Python

### Ventajas:

- APIs fáciles
- Interactividad
- Alto rendimiento (memoria y disco)

## Big Data, Hadoop y Spark



## Comparación: Hadoop vs Spark

### Rendimiento:

- Hadoop → más lento (disco)
- Spark → hasta 100x más rápido (RAM)

### Coste:

- Hadoop → más barato (disco duro)
- Spark → más caro (requiere más RAM)

### Tolerancia a fallos:

- Hadoop → archivos replicados
- Spark → RDDs replicados

### Procesamiento:

- Hadoop → por lotes
- Spark → por lotes, tiempo real y grafos

### Facilidad de uso:

- Hadoop → complejo, bajo nivel
- Spark → APIs amigables, interactivo